

Hobbeast — Üzleti kérés összefoglaló

Verzió: 1.45.0 Dátum: 2026-09-05

Valódi crawler: a gyűjtő folyamatosan bővíti a megbízható forráslistát

Eddig a felderítés egy oldalt, egy ugrást nézett. Mostantól van egy mélységkorlátos frontier-crawl, ami a bizonyított forrásokból (amelyek abban a futásban eseményt adtak) indul, és két szintig követi a hivatkozásokat, hogy olyan programközlőket találjon, akiket még nem ismerünk.

Ez a C:\Work\Smartsearchtool mappában felépített, működő crawler-tudásra épül (K4 — URL frontier, per-host részsorok, mélység szerinti prioritás; a grepsearch crawlOne/crawlBatch; a hercules SimHash és minőségpontosítás).

Élőben bizonyítva — 2 valódi forrásból (programturizmus.hu, obuda.hu) 5 igazi magyar jelölt jött ki: Veres 1 Színház, Székesfehérvár turizmus, Mézesvölgyi Nyár és mások — miközben a near-dup dedup 3 templated oldalt kiszűrte, egy fetch-hiba nem állította meg, a robots és a per-host korlát betartva.

Ami a `Smartsearchtool`-ból bekerült

SimHash near-dedup (fingerprint.mjs) — ugyanaz a lista más slug alatt ismét közzétéve egy jelölt, nem tíz. A kanonizálás a query stringet fogja meg, a SimHash a újraközlést, amit URL-ből nem lehet látni. A fingerprintet elmentjük (content_simhash oszlop), hogy egy későbbi futás is felismerje. Tartalom-minőség (contentQuality, a hercules QSDM nyelvfüggetlen fele) — a nagyon vékony, csak-váz oldalak lejjebb pontosnak, a tartalomgazdagok feljebb. Strukturált eseményt tartalmazó oldalt soha nem büntet, mert a gépi olvashatóság is tartalom. Intézményi zajsűrítés — az europa.eu, eventbrite, meetup és társaik /events útvonala eddig téves jelölt lett; most kizárva.

Korlátok — szándékosan

Egy crawl, ami nem tud kimerülni, az már nem felderítés, hanem elszabadult bot: összoldal-büdzsés, per-host cap, mélységkorlát, robots minden lekérésnél, near-dup kihagyás. Alapból kikapcsolva (--crawl 6 kapcsolja be), és a gyűjtéstől teljesen elkülönül — a futás után fut, és semmilyen hibája nem törheti el a gyűjtést.

Ez az összefoglaló 2026-09-05-én készült visszamenőleg, a CHANGELOG.md megfelelő bejegyzéséből származtatva, mert ehhez a verzióhoz eredetileg nem készült versioning-artefaktum. A tartalma a changeloból ellenőrizhető; nem a kiadás napján kelt dokumentum.