

Hobbeast — Üzleti kérés összefoglaló

Verzió: 1.57.0 Dátum: 2026-09-05

A külföldi források tényleg gyűjtenek: nyelvfüggő kinyerés + robots-megfelelés

Az 1.56.0-ban élesített 14 külföldi forrásból 12 nulla eseményt hozott. Nem a webhelyekkel volt baj: mind a 12 HTTP 200-at adott. A generikus kinyerő magyarul beszél, és ezt három helyen is teszi — az esemény-linkek útvonalszávaiban, a listakártyák hónapneveiben és a navigációs szavakban. Az /akce/, /udalost/, /repertuar/ és a „6. září 2026” egyszerűen láthatatlan volt neki.

A 12 forrás öt különböző okból bukott el (mérve, nem feltételezve):

1. Hiányzó útvonal-szókincs — Kudy z nudy, Kinodvor, Forum Karlín, Národní divadlo, Filharmonia Narodowa. A listán ott voltak a linkek (/akce/ 97 db, /film/ 50 db), csak a szűrő nem ismerte fel őket. 2. Nem ISO dátum a JSON-LD-ben — a GoOut listaoldala **36 érvényes prágai eseményt** közöl, startDate mezőben "Sat Sep 05 2026 13:00:00 GMT+0200" alakban. A parser csak YYYY-MM-DD előtagot fogadott el, így **mind a 36 eldobódott.** 3. Nap-elöl dátumok — a közép-európai 06.09.2026 és 6. září 2026 formát a magyar, év-elöl váró parser sosem illesztette. 4. Túl rövid címek — a magyar védőkortát 10 karakter alatt navigációnak minősít mindent, ami a „Kouř”, „Jony”, „Kanine” filmeket/koncerteket kidobta. 5. Rossz belépési pont vagy blokkolt letöltés — Innsbruck (403 bot user-agentre), Cankarjev dom (kategória-hub, nem eseménylista).

Megoldás: új scraper-worker/src/sources/locales.mjs, országonkénti útvonalszavakkal, hónapnevekkel (a cseh/lengyel/szlovák birtokos alakokkal együtt) és navigációs szavakkal AT/CZ/PL/SI/SK nyelvre. **A magyar viselkedés bitre azonos marad:** a localeFor() null-t ad HU-ra és minden ismeretlen országra, és minden hívási hely erre az ágra esik vissza. A country_code-ot a list_scraper_targets és list_scraper_targets_by_ids RPC adja át — egyetlen hozzáfűzött oszlop, a sorhalmaz, a rendezés és a jogosultságok változatlanok.

Mérés (valós, élő lekérés mind a 12 forráson):

Nyertesek: Wiener Konzerthaus 35, Kudy z nudy 39, Národní divadlo 37, GoOut 112, KulturServer Graz 28, Forum Karlín 28, Kinodvor 4, Slovenská filharmónia 1. Továbbra is nullás: Innsbruck, Filharmonia Narodowa, Magiczny Kraków, Cankarjev dom — ezek endpoint-javítást vagy saját receptet igényelnek, nem szókincset.

robots.txt: wildcard-minták és Crawl-delay betartása

A robots-értékelő előtag-egyezőssel dolgozott, ami minden wildcardot némán figyelmen kívül hagyott. Három most élesített forrás pontosan ilyen mintát közöl — konzerthaus.at: Disallow: /*?, goout.net: Disallow: /*/profile/, kinodvor.org: Disallow: /potrditve/* —, vagyis a worker szabadon kérte le azokat az URL-eket, amiket ezek a webhelyek kifejezetten kizártak. A minták most regexre fordulnak (* tetszőleges szakasz, záró \$ horgony). Az Allow sorok végre számítanak, a szabvány leghosszabb-egyezés elve szerint, így egy tiltott fán belüli kivétel megmarad. A Crawl-delay eddig egyáltalán nem volt beolvasva. Mostantól teljes egészében betartjuk.

Ellenőrzött hatás: 9 magyar hoston (jegy.hu, programturizmus.hu, koncert.hu, port.hu, tixa.hu, szegedvaros.hu, broadway.hu, csodalatosbalaton.hu, funcode.hu) nulla ítéletváltozás. Mind a 4 változás külföldi hoston történt, és mind olyan útvonalat zár le, amit eddig jogosulatlanul kértünk le.

> Figyelmet igényel: a jegy.hu — a platform legnagyobb forrása (5 > végpont, 450 esemény) — Crawl-delay: 20-at kér, mi eddig 400 ms-mal > dolgoztunk, azaz 50-szer gyorsabban a kértnél. A várakozás teljes > betartása mellett egy forrás felemésztené a futást, ezért a részletoldal-budget > igazodik: DETAIL_TIME_BUDGET_MS (4 perc) alapján a jegy.hu futásonként ~12 > részletoldalt kér le a korábbi 40 helyett. Ez nem veszteség, mert a kinyerő > sorsolja, melyik részletoldalakat nézi meg, így az ismételt futások > lefedik a teljes listát — de a jegy.hu frissítési üteme lassul. Ha ez nem > elfogadható, a budget egyetlen konstans.

Külföldi források élesben (AT/CZ/PL/SI/SK) + rendezhető, szűrhető forrás-tábla

14 külföldi eseményforrás élesítve. A 2026-09-04-i crawl exportjából 44 nem magyar host került elemzésre. Mindegyik kapott egy javasló és egy **adverzariálisan ellenőrző** menetet, valós HTTP-lekéréssel és robots.txt-olvasással. Ami mindkét menetet kiállta, az nem pending review-ba került, hanem élesben gyűjt (review_state='approved', scrape_enabled=true), országjelöléssel:

Az ellenőrzés valódi munkát végzett: a brno.cz elutasítva (a /akce oldal kizárólag városházi sajtóesemények — tanácsülések, szalagátvágások), a going.pl szintén. Több endpoint javításra került, és minden rekord viszi a saját robots-korlátját (a Konzerthaus Disallow: /*? miatt nem lapozható query-vel; az Innsbruck 403-at ad böngésző-User-Agent nélkül; a Graz 2 másodperces crawl-delay-t kér).

Nem minden host készült el. A 44-ből 25 csak az első menetet kapta meg, mert a munkamenet heti ügynök-limitbe futott (Sep 7-én áll vissza). Ezeket **szándékosan nem** élesítettem: a magyar V5 körben az ellenőrző menet a 39 első-menetes javaslatból 11-et elutasított és további 10-et javított — vagyis a felük hibás volt. Egy menet nem elég ahhoz, hogy egy harmadik fél oldalára élő scrapinget engedjek. Köztük van több nagy forrás (ticketmaster.pl/cz, predpredaj.sk, oeticket, snd.sk, prague.eu, teatrwielki.pl); ezek a limit feloldása után fejezhetők be.

Forrás-tábla: rendezés és oszloponkénti többszörös szűrés

Az admin /admin?tab=scrapper forrás-táblája minden oszlopon rendezhető (kattintás növekvő → csökkenő → alaphelyzet), és **minden oszlopon szűrhető, az oszlop adattípusának megfelelően**: a kategorikus oszlopoknál (Ország, Módszer, Kategóriák, Hozzáférés, Állapot) többszörös kiválasztás a ténylegesen előforduló értékek közül, a Forrásnál szabadszavas keresés névre/URL-re/városra, a dátum-oszlopnál „futott már / még nem futott”. A szűrők oszlopon belül VAGY, oszlopok között ÉS kapcsolatban állnak.

Új Ország oszlop zászlós címkével. A fejléc jelölőnégyzete pontosan a szűrésen átjutó sorokat jelöli ki, és van „Mind a N kijelölése” gomb is — így például a lengyel jegyértékesítőkre szűkítve egy kattintással átadható a halmaz egy begyűjtő futásnak.

A tábla saját komponensbe került (ScrapperSourcesTable), a szűrő/rendező logika pedig egy tiszta, renderelés nélkül tesztelhető modulba (scrapperSources.ts) — 16 új unit teszt fedi.

NativeBootstrap: a Capacitor-pluginnek már csak natívon töltődnek

A korábban jelzett tétel. A @capacitor/app, status-bar, splash-screen és a notifications modul mostantól dinamikus import()-tal, a natív ág belsejében töltődik, így webre nem kerül olyan kód, ami ott sosem futhat. Csak a @capacitor/core marad statikus, mert a platform-ellenőrzés szinkron módon kell.

Őszinte mérés: ez az app-shellből 176805 → 175908 nyers bájtot (−897), gzip-ben 56297 → 55948-at (−349) hozott vissza — jóval kevesebbet, mint a korábban becsült ~9 KB. A becslésem téves volt: a súly zöme a @capacitor/core maga, nem a vékony plugin-wrapperek. A core kiemeléséhez a window.Capacitor globálison keresztüli detektálás kellene, ami natív regressziót kockáztatna, ezért nem tettem meg. A teljesítmény-keret így változatlan marad.

Kockázatmentes: az alkalmazás már eddig is dinamikus importtal töltötte minden útvonalát, tehát a Capacitor WebView-ban ez bizonyítottan működő minta. Ellenőrizve: cap sync android mind az 5 plugint feloldotta, gradlew assembleRelease → BUILD SUCCESSFUL (27,8 MB APK).

Ez az összefoglaló 2026-09-05-én készült visszamenőleg, a CHANGELOG.md megfelelő bejegyzéséből származtatva, mert ehhez a verzióhoz eredetileg nem készült versioning-artefaktum. A tartalma a changeloból ellenőrizhető; nem a kiadás napján kelt dokumentum.