

Hobbeast — Üzleti kérés összefoglaló

Verzió: 1.58.0 Dátum: 2026-09-05

A külföldi forrás-vetting befejezése: +20 forrás, 8 elutasítva

A v1.56.0 a 44 crawlolt külföldi hostból csak azt a 14-et élesítette, amelyik mindkét menetet — a javaslot és az adverzariálisan ellenőrzött — kiállta. A maradék 25 host csak az első menetet kapta meg, mert a futás 2026-09-04-én elérte a heti agent-limitet; további három (oeticket.com, ticketportal.cz, eventim.pl) egyáltalán nem volt vizsgálva. Ez a kiadás megadja nekik a járó második menetet.

Az ellenőrzés újra megérte: 28-ból 8 elbukott — 29%. (A magyar V5 körben 39-ből 11 elutasítás + 10 javítás volt; az arány nem esett össze.) Egy menet továbbra sem elég ahhoz, hogy éles scrapinget irányítsunk valaki más oldalára.

+20 forrás élesben (review_state='approved', legal_review_status='approved', robots_allowed=true, enabled=false, scrape_enabled=true, országgóddal):

A regiszter így 411 forrás: 377 HU + 14 (V6) + 20 (V7).

8 elutasítva, mindegyik valós okkal. A kosice.sk nem naptár, hanem gyűjtőcikk: 3-4 esemény, azok dátuma (2026 május/június) már el is múlt. Az opera.si /sl/program/koledar/ oldala HTTP 200-at ad, de 1,2 KB szöveget és nulla eseményt — kliensoldalon rendereli az eventList.bundle.js; a ház dátumozott előadásai amúgy is befutnak a mojekarte.si-n keresztül, ahol maga az opera.si árulja a jegyet. A salzburgerfestspiele.at szintén JS-váz, ráadásul a 2026-os fesztivál augusztus 30-án véget ért. A ticketportal.sk és .cz szerveroldali HTML-je lefordíthatatlan SPA-sablon: szó szerinti [SK|lbKategorie] és %ValidDate% helyőrzők, Lorem ipsum, egy 2017-es demó-esemény — nulla 2026/2027-es dátum és nulla JSON-LD az egész dokumentumban. Az eventim.si, oeticket.com és eventim.pl elérhetetlen: böngésző-UA-s curl IPv4-en és IPv6-on, plusz a WebFetch — két független kimenő út — mind time-outot vagy connection resetet kap. Az V5-ös tanulság áll: élő lekérés nélkül nincs forrás.

Javított végpontok. A predpredaj.sk valójában a predpredaj.zoznam.sk aldomainen szolgál ki, a musikverein.at naptára pedig a spielplan.musikverein.at-on — a dedupot mindkettőnél a végleges hostra kell futtatni, nem a márkanévre. A wien.info végpontja nem HTML, hanem ~425 KB JSON ({ "type": "events", "items": [...] } ISO dátumokkal); a format és a parser_strategy a valódi alakot rögzíti.

Minden sor viszi a rá vonatkozó robots-megkötést. A prague.eu Crawl-delay: 600-at kér — tíz perc két kérés között, a regiszter legszigorúbb értéke —, plusz Disallow: /*?* (semmilyen query string) és Disallow: /wp-json/; egy lekérés viszont ~870 eseményt ad, így elfér benne egy napi hívás. A mojekarte.si és a wiener-staatsoper.at név szerint tiltja a ClaudeBot, anthropic-ai, GPTBot, CCBot, PerplexityBot és társai UA-ját Disallow: /-sal — a gyűjtő tehát kizárólag saját, őszinte Hobbeast UA-val futhat, ami az általános User-agent: * csoport alá esik. A wiener-staatsoper.at ezen felül Cloudflare Content-Signal: search=yes, ai-train=no, use=reference jelzést ad, kifejezett Article 4 (EU DSM) jogfenntartásként: a tényadatot tároló, visszalinkelő eseményindex a search=yes / use=reference alá esik, tanítás nem. A poznan.pl és az snd.sk Crawl-delay: 10-et kér. Az events.at, a mojekarte.si és a wiener-staatsoper.at böngésző-UA nélkül 403-at ad.

* Egy sor szándékosan scrape_enabled=false: a www.wien.info. A végpontja ellenőrzött és robots-tiszta, de a payload egyedi {items:[...]} JSON, amit a worker egyik stratégiája sem tud olvasni — a jsonld <script type="application/ld+json"> tageket vár, a wp-posts a WordPress REST alakot, a render pedig Playwrightot eresztene rá egy JSON dokumentumra. Élesítve csak consecutive_failures-t gyűjtene. Regisztrálva marad, hogy a végpont és a robots-tisztázás ne vesszen el; a kapcsoló akkor billenthető, ha lesz rá site adapter vagy json-items stratégia.

Két stratégia nem render, és mindkettő a worker saját kódútján lett igazolva — nem feltételezve. A

kultura.maribor.si tribe: a scrapeTribeSource() az endpoint_url-ből képzett

{origin}/wp-json/tribe/events/v1/events hívása HTTP 200-at adott, total=29, total_pages=6, pontosan azokkal a mezőkkel, amiket az adapter olvas. A go2warsaw.pl jsonld: egy GET 490 KB-ot hozott 1034 application/ld+json blokkal, mind a 1034 parse-olt és mind @type=Event, name + startDate + location.name hármassal — épp az a szerződés, amit a parseJsonLdEvents() megkövetel.

Dedup és bizonyítás. A 20 host egyike sem ütközik a repóban rögzített 220 endpoint-hosttal (ez lefedi mind a 378 src_* azonosítót), az aldomainek apex alakját is beleértve. A Supabase MCP ebben a munkamenetben nem volt elérhető, így az élő tábla közvetlenül nem volt lekérdezhető — a migráció host-szintű NOT EXISTS öre a mérvadó védőháló, ami alkalmazáskor az élő tábla ellen fut. A bun run db:verify nem tud kaput adni erre a migrációra: a --mode=fresh a 20260825090000-nél elhasal, mert annak korai utasításai a hosztolt platform auth sémáját és az app_runtime_config-ot igénylik — korábban meglévő törés, ami jóval e fájl előtt rendeződik. Helyette eldobható PostgreSQL 18 klaszterben, a platformobjektumokat kistubolva és a regiszter-táblát + segédfüggvényeit + a scrape_* oszlopokat szó szerint visszajátszva futott a V6 és a V7 szigorúan (ON_ERROR_STOP=1 --single-transaction): 17/17 ellenőrzés zöld. A legfontosabb közülük az ör tesztje: egy előre elhelyezett https://snd.sk/anything-else sor mellett újrafuttatva a migráció 19 sort szűrt be és az snd.sk-t csendben kihagyta — tehát a host-ör deduplikál, nem csak az ON CONFLICT. Részletes jegyzőkönyv: docs/releases/MIGRATION_RECORD_v1.57.0_foreign_event_sources_v7.md.

Az enabled minden soron false marad (az a legacy no-JS feed-csővezetékét vezérli); a scrape_enabled=true a Playwright worker sorába teszi a 19 forrást, az üzemeltető pedig bármelyiket felülvizsgálhatja vagy szüneteltetheti a /admin?tab=scrapper felületen.

Élesítés és a `Crawl-delay: 600` költségvetési hibája

A V7 migráció egy külön munkamenetben készült, amelynek nem volt DB-hozzáférése, ezért a fájl megvolt, de sem a main-be, sem az éles adatbázisba nem került be. Itt kapta meg mindkettőt.

Élő dedup, amit a vetting nem tudott elvégezni. A V5 tanulság szerint a migrációs fájlok alulbecsülik a tábla valós tartalmát, ezért mind a 20 source_id-t és mind a 20 hostot az éles tábla ellen ellenőriztem: nulla ütközés. A migráción belül is 20 sor / 20 egyedi id — fontos, mert ON CONFLICT (source_id) DO NOTHING mellett egy belső duplikátum némán elnyelt volna egy sort. Alkalmazás után a tábla 411 sor (377 HU + 34 külföldi), ebből 398 scrape_enabled.

A saját 1.57.0-s hibám javítva. A Crawl-delay betartásához bevezetett DETAIL_TIME_BUDGET_MS egy Math.max(4, ...) alsó korláttal érkezett. A V7 behozta a prague.eu-t, amely Crawl-delay: 600-at kér — az alsó korlát mellett ez 4 részletoldal × 600 s = 40 perc egyetlen forrásra, egy 50 perces futásból. Az alsó korlát megszűnt: ha a keret egyetlen udvarias lekérésre sem elég, a forrás nulla részletoldalt kér le, és csak azt tartja meg, amit maga a listaoldal ad (JSON-LD + kártyák). Ez egyben a helyes olvasata egy ekkora várakozási kérésnek.

Ez az összefoglaló 2026-09-05-én készült visszamenőleg, a CHANGELOG.md megfelelő bejegyzéséből származtatva, mert ehhez a verzióhoz eredetileg nem készült versioning-artefaktum. A tartalma a changeloból ellenőrizhető; nem a kiadás napján kelt dokumentum.