

Hobbeast — Üzleti kérés összefoglaló

Verzió: 1.61.0 Dátum: 2026-09-05

Perzisztens gyűjtő-frontier: a futások folytatják egymást, nem újrásorsolnak

Eddig a gyűjtő minden futásban lerenderelte a forrás listaoldalát, összeszedte a linkeket, sorsolt belőlük 40-et, letöltötte, és mindent elfelejtett. Egy 300 eseményes listánál ugyanazok az oldalak jöttek vissza újra és újra, mások sosem nyíltak ki. A grepsearch crawler (event_queue) ehelyett URL-szintű sort vezet — pending/running/done/error, prioritás, mélység, mit adott az oldal —, és minden futás a sor tetejéről folytatja.

****Egymást követő futások konvergálnak a teljes lefedettségre.****

Ez az a sor, integrálva, nem cserélve: minden meglévő kinyerő út (JSON-LD, microdata, kártyák, locale-szókinsz, robots + Crawl-delay, feltételes GET, forrásonkénti időkeret, hub-retry, képek) érintetlen. A frontier ****kizárólag a részletoldal-letöltés lépését**** fogja körbe. collection_frontier tábla — forrásonként (nem globálisan, mint a grepsearch-nél): a jegy.hu 5 végponttal él ugyanazon a hoston, mindegyiknek a saját haladását kell vezetnie, ezért UNIQUE (source_id, url). RLS: providers.manage olvashat, kliens nem ír. Hat RPC, mind service_role-only: enqueue (ON CONFLICT DO NOTHING — egy már látott link sosem duplikálódik), claim (elárvult claim-ek felszabadítása egy óra után; pending-elöl, prioritás DESC, mélység ASC, legrégebben lekért elől; backoffban lévő hostok kihagyva; FOR UPDATE SKIP LOCKED), finish (hiba → 3 kísérletig visszakerül felezett prioritással), release (időkeret-fogyáskor running → pending), note_host_backoff / clear_host_backoff — a 429/503 a már létező, de eddig üres crawl_host_state táblába parkolja a hostot. crawl_config.collection_frontier_enabled — kill switch. Ha kikapcsolod, vagy az RPC-k bármelyike hibázik, a régi sorsolás fut változatlanul. Ez a regresszió-garancia, és a kód szintjén is: frontier hiányában a scrapeGenericSource ugyanaz az ág, mint eddig. Prioritás link-alak szerint: dátum vagy numerikus azonosító az útvonalban, vagy

Bizonyítás, nem feltételezés: Élő RPC-teszt service_role-ként, 12/12: dedup, claim-sorrend, futó sorok kizárása a második claimből, ETag tárolás, hiba-visszaesés felezett prioritással, release, backoff elrejtí a hostot, clear visszahozza, authenticated elutasítva (42501). Takarítás után nulla próbasor maradt. Konvergencia valódi oldalakon (kétszer futtatva, in-memory sorral): SND, GoOut és koncert.hu (magyar kontroll) — mindháromnál a 2. futás 12 más URL-t kért le, mint az 1., átfedés 0, unió 24. A sorsolásnál ugyanazok jöttek volna vissza. Worker tesztkészlet 154 → 186, admin 31 zöld, admin_scraper_stats a régi és az új kulcsokkal is válaszol (396 destination).

Egy governance-lyuk, amit közben találtam: a scripts/audit-security-definer.mjs csak a 2026-08-22/25/26-i migrációkat vizsgálja (/^202608(?:22|25|26)/). ****Augusztus 26. óta egyetlen migráció sincs auditálva**** — az RLS-ek, a country_code, ez sem. Ezért állt a szám 300/81-en végig. Külön bejegyzésben kezelem.

Ez az összefoglaló 2026-09-05-én készült visszamenőleg, a CHANGELOG.md megfelelő bejegyzéséből származtatva, mert ehhez a verzióhoz eredetileg nem készült versioning-artefaktum. A tartalma a changeloból ellenőrizhető; nem a kiadás napján kelt dokumentum.