

Hobbeast — Üzleti kérés összefoglaló

Verzió: 1.64.0 Dátum: 2026-09-05

A négy nullás külföldi forrás — szelektoros recept, nem újabb heurisztika

A locale-munka (v1.57–v1.60) után négy engedélyezett külföldi forrás maradt nullán, és mindegyik más okból. Egyiket sem lehetett volna újabb általános találgatással megoldani: az információ egyszerűen nem ott van, ahol a generikus kinyerő keresi. A selector stratégia viszont már létezett — így ez négy adatsor és egyetlen kódbeli engedélyező változás, nem új kinyerő ág.

Minden receptet az élő DOM-ból írtam meg, majd a valódi selector stratégiával mértem. Az alábbi számok a jövőbeli dátumú eseményekre vonatkoznak — arra, amit az ingest ténylegesen megtart:

Az engedélyező változás (scraper-worker/src/sources/recipeRunner.mjs): a selector stratégia a dátummezőt parseHuTextDate-tel olvasta, ami nem érti a lengyel "5.09"-et vagy a szlovén "7. - 10. sep."-et. Mostantól a forrás country_code-jából választott locale-parsert használja, a magyarra visszaesve. Egy magyar recept viselkedése bitre azonos a korábbival: localeFor() HU-ra és minden ismeretlen országra null-t ad.

Új parser (parseLocaleFieldDate): olyan alakokat is elolvas, amiket a szabad szöveges parseLocaleTextDate szándékosan visszautasít — például az évszám nélküli "5.09"-et. Ez azért biztonságos, mert a recept megnevezi azt az elemet, amelyik a dátumot tartalmazza: ha oda "5.09" érkezik, az dátum. Ugyanez a minta laza oldalszövegben árakra és eredményekre is illeszkedne — a szabad szöveges parser ezért utasítja el továbbra is.

Két hiba, amit a mérés fogott meg és teszt rögzít: A tartomány mindig a KEZDETÉT adja. Az "05 Sep 26 - 26 Dez 26" ág sorrendje először rossz volt, és a végét vette — egy szeptemberi esemény decemberbe került volna. A tartomány végén kiírt évszám veri a következtetést. A "30. jun. - 13. sep. 2026" kezdete így 2026 június; nélküle múltbelinek látszott, átfordult 2027-re, és egy teljes évet tévedett.

Forrásonként, amit a mérés kiderített: Magiczny Kraków — a kártya p.text__date mezője ISO tartományt tartalmaz ("2026-04-17 - 2026-12-18"), és a hosszú futású tételek múltbeli kezdődátuma miatt 20-ból 19 kiesett volna a jövőbeli-dátum kapun. A href viszont tartalmazza azt a napot, amelyre a lista szól — egy napi kalendáriumnál ez a „ma mi van műsoron” helyes olvasata. Filharmonia Narodowa — a részletoldalakon nincs strukturált eseményadat, a listán a horgony körül csak hétköznapi és időpont áll ("niedziela / 18:00"); a dátum külön .event-date mezőben, év nélkül. Innsbruck Tourismus — a részletoldalak bot user-agentre 403-at adnak, és a listán talált linkek kategória-oldalak voltak; a renderelt listán viszont ott a .pcl25-entry kártya. Cankarjev dom — a ház kínálata többnyire hosszú futású kiállítás, aminek a kezdődátuma már elmúlt. Az ingest ezeket helyesen eldobja: 1 esemény gyenge, de valós hozam — nem hibás nulla.

Élesben mérve: a Kraków már az első futáson +20 eseményt hozott. A másik három azon a futáson még nullát adott, mert a main akkor még nem ismerte a parseLocaleFieldDate-et — a Kraków dátuma a href ISO szegmenséből jön, ezért neki nem is kellett. Ez a kiadás pontosan ezt a különbséget szünteti meg.

Migráció: 20260905230000_selector_rules_zero_yield_sources.sql — négy UPDATE, minden sorban a recept és a scrape_note, ami leírja, miért pont az a mező. A recept adat: semmi nem hajtodik végre belőle, csak elemeket és attribútumokat nevez meg.

Ez az összefoglaló 2026-09-05-én készült visszamenőleg, a CHANGELOG.md megfelelő bejegyzéséből származtatva, mert ehhez a verzióhoz eredetileg nem készült versioning-artefaktum. A tartalma a changelogloból ellenőrizhető; nem a kiadás napján kelt dokumentum.