

Hobbeast — Üzleti kérés összefoglaló

Verzió: 1.67.0 Dátum: 2026-09-05

907 munkafüzet sorból 74 forrás, amiből 41 tényleg gyűjt

A tulajdonos négy Excel-fájlt adott át hat országhoz. Az abroad sources.xlsx valódi szuperhalmaznak bizonyult — ellenőrizve: a másik három fájlból nulla olyan endpoint van, amit ne tartalmazna —, így minden ebből származik.

A tölcser, minden lépés mérve, nem feltételezve:

Az utolsó sor az egyetlen, ami számít. A V6-nál mind a 14 forrás átment két ítélomeneten, aztán tizenkettő nullát gyűjtött. Egy forrást futás bizonyít, nem forrássor. Ezért minden sor a worker saját kinyerőjén ment át, és a parser_strategy mezőben ott a 2026-09-05-i darabszám valódi eseménycímekkel.

Országokként (bekapcsolt / regisztrált): **SI 13/22, DE 9/16, CZ 8/15, AT 6/8, PL 5/8, SK 0/5**. A regiszter 415 → 489 sorra nőtt, a külföldi rész 34 → 108-ra.

A 33 kikapcsolt sor nem az átvizsgálás kudarca. Két független menet elolvasta őket, és valódi jövőbeli eseményeket nevezett meg rajtuk — a *mi generikus kinyerőnk* nem boldogul velük. Mindegyik sor leírja, mi kellene neki. A regisztráció megőrzi az endpointot és a robots-tisztázást; a visitberlin.de, a visitczechia.com, a deutscheoperberlin.de és az eventfrog.at a legértékesebb megírandó receptek. Ez a V7-ben lefektetett wien.info-precedens.

Szlovákia 5 sort kapott és nulla bekapcsoltat. Minden átvizsgálást túlélő szlovák lista receptet kíván. Ez őszinte nulla, nem kihagyás.

Amit a munkafüzetekről tudni érdemes

Ez a legfontosabb visszajelzés a következő adaghoz: 151 az 515 jelölt URL-ből sima HTTP 404 volt. További 46-nak egyáltalán nem élt a hosztja (nem létező domain, lejárt vagy önálírt tanúsítvány, kapcsolat-timeout). Hosszabb időkorláttal újrapróbáltam mind az 50 átmenetnek tűnő esetet: egy sem javult. A 72 elutasított sorból 33 egyetlen rendezvény volt, nem programlista — egy fesztivál, egy maraton, egy szakvásár. Németország a legrosszabb: 29-ből 14. További 10 csak múltbeli eseményeket listázott. A német lap 500 sora 184 egyedi endpoint: a germany.travel 195-ször, az eventfinder.de 117-szer ismétlődik benne.

A cáfoló menet megint kifizetődött, 85-ből 8-at lőtt ki: üres JS-héjakat, amiknek a naptára soha nem renderelődik, egy soft-404-et, egy fesztivál szerkesztőségi dátumcikkét, és egy szakvásár-feedet kultúrának álcázva. Ráadásul 74-ből 60-nak korrigálni kellett az endpointját — a munkafüzet URL-je jellemzően nem a programlista URL-je volt.

Két saját hiba, mindkettőt a mérés fogta meg, nem az átolvasás

A szonda félkész DE locale-lal futott. A EVENT_PATH_WORDS-be már bekerült a DE, a MONTH_WORDS-be még nem, így a localeFor('DE') egy olyan locale-t adott vissza, aminek undefined a hónaptáblája — és elszállt. Ez **64 német jelöltet utasított el igazságtalanul; újrasondázva 25** megkerült. A shmf.de-t rossz stratégiával mértem. Az endpoint text/calendar, én mégis a render úton hajtottam rá, ami „page.goto: Download is starting” hibával elszállt. A saját, deklarált ics stratégiájával újramérve **három valódi koncertet ad, tehát be van kapcsolva. Egy forrást azzal a stratégiával kell tesztelni, amit állít magáról, nem az alapértelmezettel.**

Egy harmadik hibát a *séma* fogott meg, nem én: a selector stratégiához CHECK-constraint köti a scrape_rule meglétét, és három recept nélküli sort visszautasított. Jogosan — render-re kerültek, a jegyzetük mondja meg, hogy recept kell.

robots.txt

Mind a 74 elfogadott hosztra lekérve 2026-09-05-én: minden útvonal engedélyezett. Négy kér Crawl-delay-t (stantonamarlberg.com 10 s, visitkoper.si 5 s, kultura.poznan.pl 2 s, schwerin.de 1 s); a worker betartja, és 5 s fölötte csak a listát olvassa.

Itt is volt egy saját hiba: a robots-gyűjtőm az `allowsPath()`-nak a teljes `{rules, crawlDelay}` objektumot adta a szabálytömb helyett, ezért `*„rules is not iterable”*` kivétellel elnyelte mind a négy Crawl-delay-t, és a generált szöveg azt állította volna, hogy egyik sem kér késleltetést. A worker maga végig helyesen olvasta — ezt külön leellenőriztem a `stantonamarlberg.com-on` (Crawl-delay: 10 → 10000 ms) —, szóval szabálysértés nem történt, de az adatbázisba tényhiba került volna.

Külön figyelmet kapott, hogy több fájlban üres Disallow: áll, ami `*mindent engedélyez*`. Elválasztóval összefűzve ez pont úgy néz ki, mint a mindent tiltó Disallow: /. Tizenhárom hosztot érint; a döntés végig parseolásból született, nem ránézésből, és a szöveg most kimondja, melyikről van szó.

Ez az összefoglaló 2026-09-05-én készült visszamenőleg, a CHANGELOG.md megfelelő bejegyzéséből származtatva, mert ehhez a verzióhoz eredetileg nem készült versioning-artefaktum. A tartalma a changeloból ellenőrizhető; nem a kiadás napján kelt dokumentum.