

Hobbeast — Üzleti kérés összefoglaló

Verzió: 1.68.0 Dátum: 2026-09-05

A gyűjtő mostantól mindenhol megmondja, kicsoda

A scraper-worker/src/fetch.mjs eddig is az őszinte HobbeastBot/1.0 (+https://expericentre.com; event aggregation) UA-t küldte — a Playwright renderelő út viszont nem. A renderPage() (generic.mjs:572) és a scrapeTelekomSpots() (adapters.mjs:19) sima asztali Chrome user-agentet küldött, ami sehol nem azonosított minket. Mivel a render és a selector stratégia viszi a források túlnyomó részét, a gyűjtés nagyobbik fele gyakorlatilag névtelenül futott.

Ez ütközött a projekt álló szabályával: ****soha ne adjuk ki magunkat másnak, és ne kerüljük meg a bot-védelmet****. Rosszabb: a 20260905143000 migráció az events.at-hez ezt rögzítette — ***,MUST send a desktop Chrome User-Agent: WebFetch and plain Node fetch both get HTTP 403, while curl with a browser UA plus Accept-Language: de-AT returns 200 every time**** —, ami kimondottan 403-kerülésre használt böngésző-UA.

A javítás nem a Chrome-token eldobása. Egy valódi Chromium végzi a renderelést, tehát a kompatibilitási string igaz; a bevett őszinte gyakorlat az, hogy a saját tokenünket hozzáfűzzük:

Egyetlen helyen van definiálva (RENDER_UA a fetch.mjs-ben), és mindhárom hívási hely onnan veszi — a renderelő és a fetch út így nem tud szétcsúszni az identitásban.

Ehhez tartozik a robots.txt másik fele

Ha megmondjuk, kik vagyunk, egy oldal nekünk címezhet szabályt — és eddig azt csendben figyelmen kívül hagytuk volna: a parseRobots() kizárólag a User-agent: * csoportot olvasta. Mostantól csoportokra bont, és ****a** minket megnevező csoport felülírja a wildcardot******, ahogy a szabvány kéri. Ez volt a párja az őszinte azonosításnak: kérni, hogy szóljanak hozzánk, majd nem odafigyelni, félmunka lett volna.

Két apróság, amit menet közben tesztben rögzítettünk: Több egymást követő User-agent: sor EGY csoportot nyit (az eventfrog.at és az orto-bar.com is így ír). Több User-agent: * blokk egyesül. A visitkoper.si valóban kettőt ír: az egyik a Crawl-delay-t, a másik a Disallow listát hordozza. A csoportosítás előtti kód is így viselkedett, ezt meg kellett őrizni.

Ma egyetlen forrásunk robots.txt-je sem nevez meg minket, tehát a csoportválasztás mai viselkedése bitre a régi — ez előretekintő helyesség, nem viselkedésváltozás. 8 új teszt rögzíti (219 zöld).

Mérve, nem feltételezve

1. Izolált A/B/C 31 hoszton, ugyanazzal a böngészővel és időzítéssel, egyetlen változóval:

Az egyetlen tartalmi eltérés a festspiele-mv.de: 3041 → 2564 karakter, három egymás utáni körben reprodukálhatóan, tehát valódi UA-függés. Ráakva a valódi kinyerőt viszont mindkét UA-val ****27** esemény, 27 egyedi cím, ugyanazok — sávszöveg a különbség, nem tartalom. Nulla eseménybe kerül.******

A prague.eu a fordított eset: a tiszta bot-UA-val esik vissza a tartalom, a Chrome-tokennel együtt nem. Ezért nem dobtuk el a kompatibilitási stringet.

2. Éles A/B, ugyanaz a 28 forrás HU/AT/CZ/DE/PL/SI/SK-ból, gh workflow run előtte (main) és utána (honest-render-ua ág):

A különbség egyetlen forrás sem a UA miatt van — minden eltérést külön lemértünk: koncert.hu 167 → 0 és spielplan.musikverein.at 136 → 0: mindkettő page.goto: Timeout 30000ms, nem elutasítás. A koncert.hu-t ****ugyanazon az ágon újrafuttatva 195 esemény**** jött — többet a bázisnál. A musikverein a CI-ből másodszor is időtúllépett, innen viszont ****HTTP 200, ~250 ms, azonos 18197 karakter mindkét UA-val**** — a CI hálózati útvonalára jellemző, korábbról ismert eset. oberstdorf.de 163 → 101: helyben mérve ugyanaz az 50 egyedi cím mindkét UA-val (az őszintével 125 sor a 111 helyett). Az ingadozás az ismétlődő időpontokból jön. tixa.hu 102 → 83: helyben bitre azonos (93/83) mindkét UA-val. Ez a forrás listaoldala 404-et ad és a gyökerre esik vissza — korábbi állapot. A többi eltérés ±2 körül, és három forrás nőtt: wroclaw.pl +27, mgml.si +19, events.at +7.

****Egyetlen forrás sem veszít hozamot az őszinte UA-tól, tehát egyiket sem kellett kikapcsolni.****

Az `events.at` állítása megdőlt

Mind a három UA-val — a **csak** HobbeastBot-tal is — ****HTTP 200 és azonos, 7758 karakteres oldal****. A jegyzet két dolgot kevert össze: a 403 a WebFetch-nek és a sima Node fetch-nek szólt, azaz nem böngésző HTTP-kliensnek; a Playwright valódi böngésző, és a UA-szövegtől függetlenül kiszolgálják. A renderelő úton tehát soha nem is kellett megszemélyesítés — a jegyzet egy nem létező kényszert írt elő.

Ugyanez a három másik forrásnál, aminek a jegyzete böngésző-UA-t emlegetett: innsbruck.info, forumkarlin.cz, mojekarte.si — mindhárom azonos mindhárom UA-val. A cáfolt állítás javító migrációval kikerült az events.at sorából.

Ez az összefoglaló 2026-09-05-én készült visszamenőleg, a CHANGELOG.md megfelelő bejegyzéséből származtatva, mert ehhez a verzióhoz eredetileg nem készült versioning-artefaktum. A tartalma a changeloból ellenőrizhető; nem a kiadás napján kelt dokumentum.